Ejercicio 1

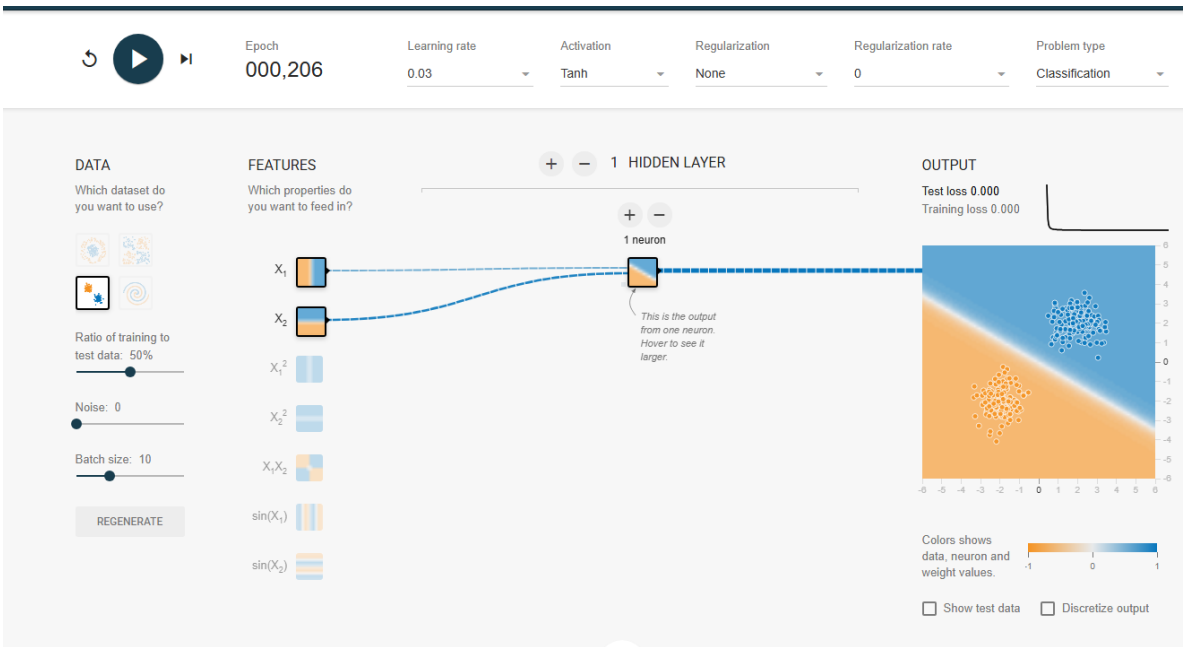
Epoch
000,206
Learning rate
0.03
Activation
Tanh
Regularization
None
Regularization rate
0
Problem type
Classification
DATA
Which dataset do you want to use?
Ratio of training to test data: 50%
Noise: 0
Batch size: 10
REGENERATE
FEATURES
Which properties do you want to feed in?
1 HIDDEN LAYER
1 neuron
This is the output from one neuron. Hover to see it larger.
OUTPUT
Test loss 0.000
Training loss 0.000
Colors shows data, neuron and weight values.
Show test data
Discretize output

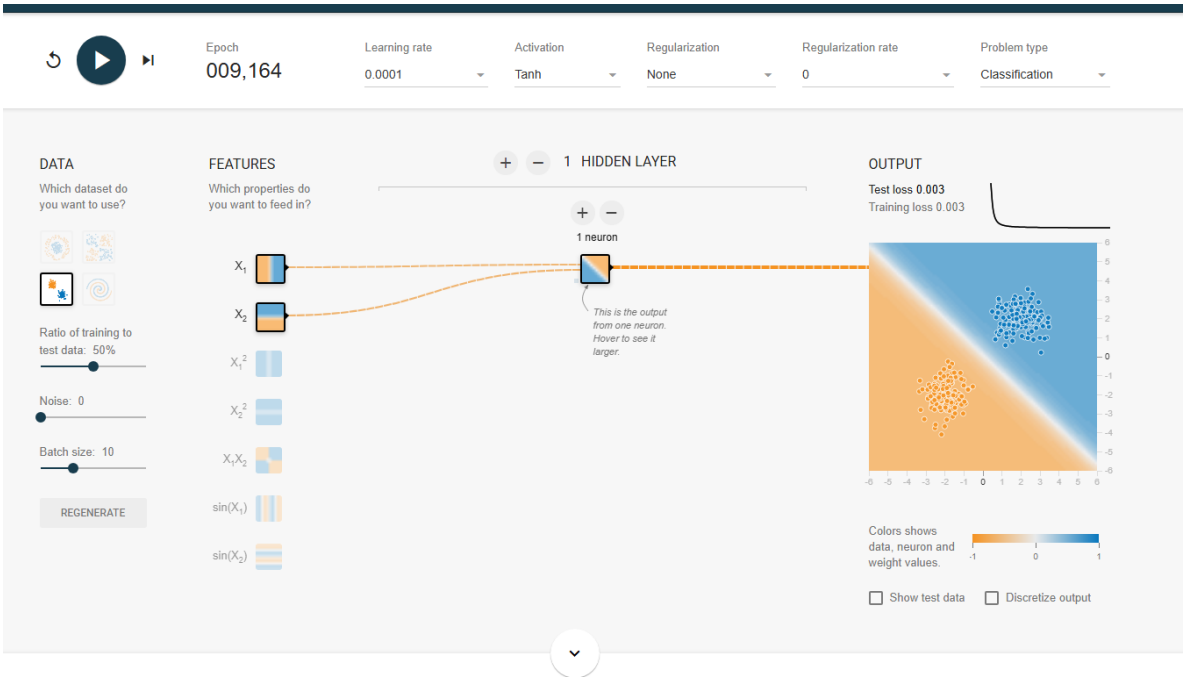
Epoch
009,164
Learning rate
0.0001
Activation
Tanh
Regularization
None
Regularization rate
0
Problem type
Classification
DATA
Which dataset do you want to use?
Ratio of training to test data: 50%
Noise: 0
Batch size: 10
REGENERATE
FEATURES
Which properties do you want to feed in?
1 HIDDEN LAYER
1 neuron
This is the output from one neuron. Hover to see it larger.
OUTPUT
Test loss 0.003
Training loss 0.003
Colors shows data, neuron and weight values.
Show test data
Discretize output

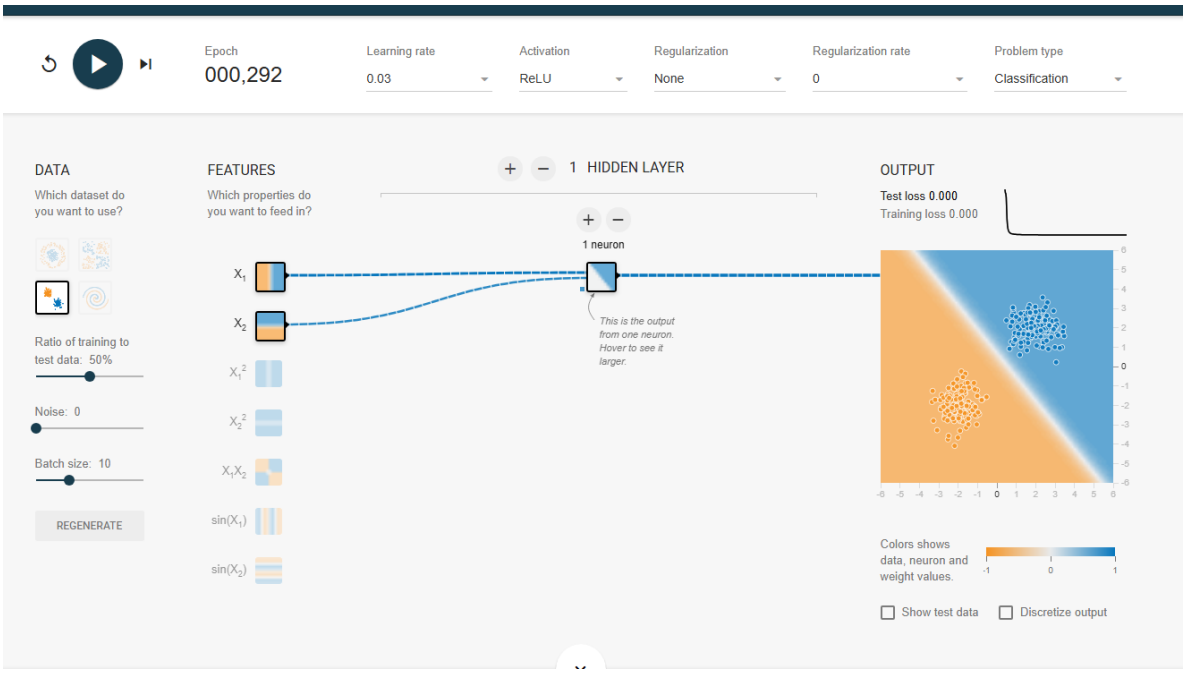
Epoch
000,292
Learning rate
0.03
Activation
ReLU
Regularization
None
Regularization rate
0
Problem type
Classification
DATA
Which dataset do you want to use?
Ratio of training to test data: 50%
Noise: 0
Batch size: 10
REGENERATE
FEATURES
Which properties do you want to feed in?
1 HIDDEN LAYER
1 neuron
This is the output from one neuron. Hover to see it larger.
OUTPUT
Test loss 0.000
Training loss 0.000
Colors shows data, neuron and weight values.
Show test data
Discretize output

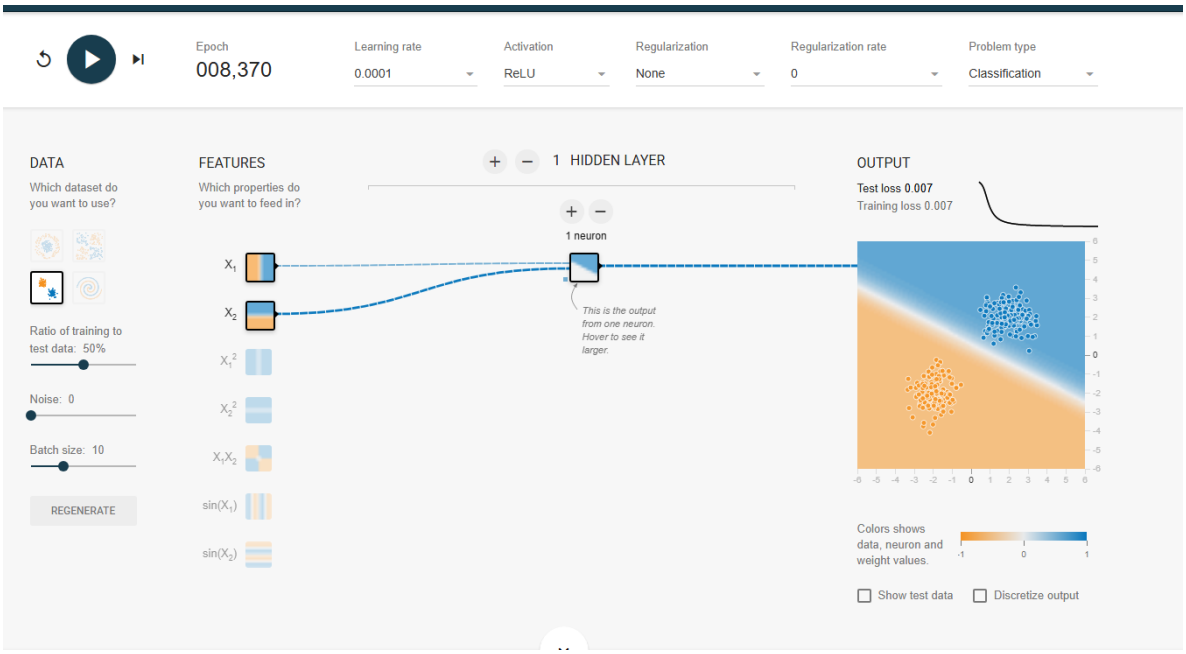
Epoch
008,370
Learning rate
0.0001
Activation
ReLU
Regularization
None
Regularization rate
0
Problem type
Classification
DATA
Which dataset do you want to use?
Ratio of training to test data: 50%
Noise: 0
Batch size: 10
REGENERATE
FEATURES
Which properties do you want to feed in?
1 HIDDEN LAYER
1 neuron
This is the output from one neuron. Hover to see it larger.
OUTPUT
Test loss 0.007
Training loss 0.007
Colors shows data, neuron and weight values.
Show test data
Discretize output

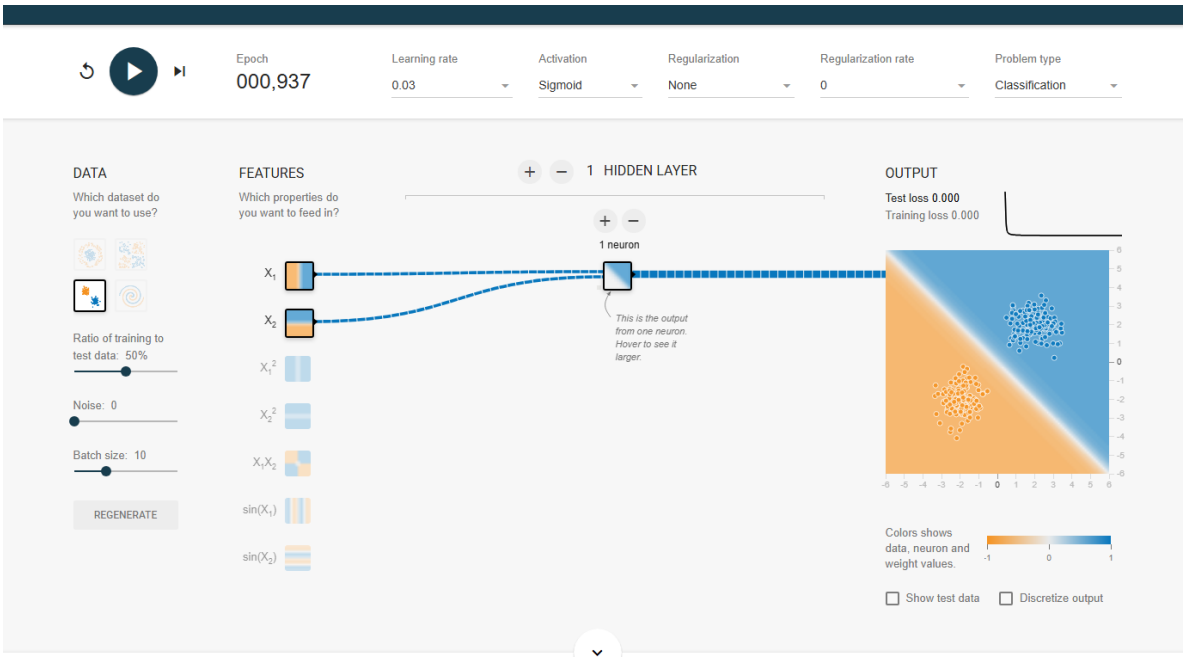

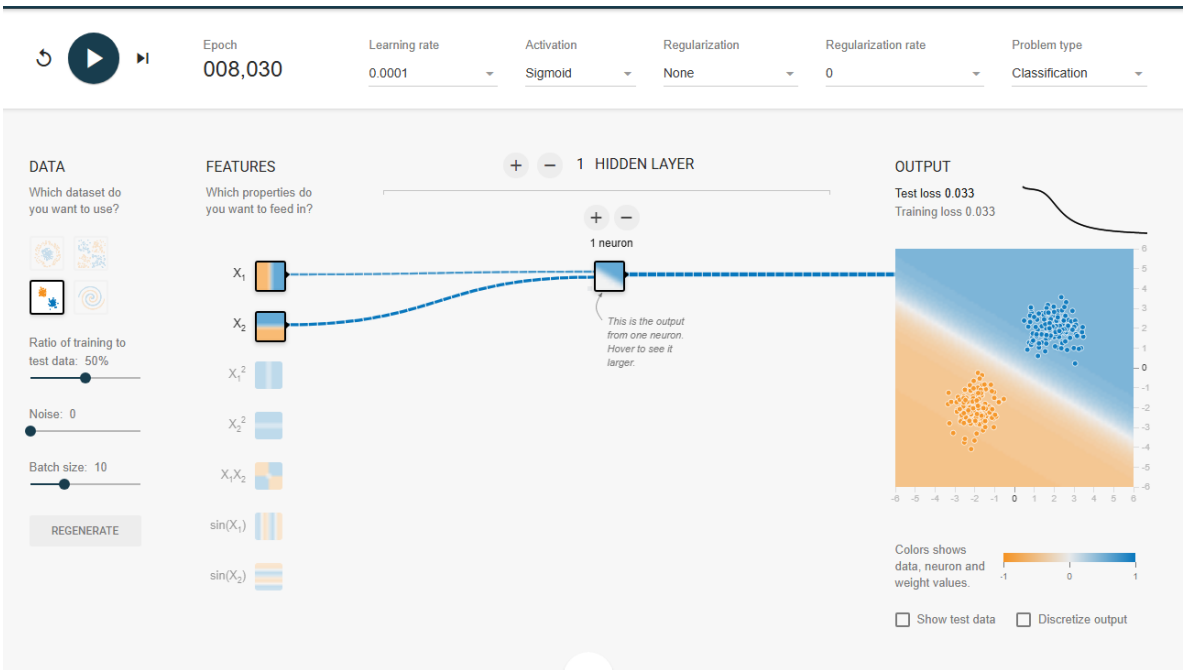

1. ¿Con qué función de activación aprende más rápido?

Con ReLU o Tanh.

ReLU llegó a cero error en solo 292 épocas.

Sigmoid es la más lenta; necesitó más de 8,000 épocas y aun así no llegó a cero.

2. ¿Qué pasa cuando el learning rate es muy alto?

La red se vuelve inestable.

Los pesos cambian de forma tan brusca que "saltan" sobre la solución óptima sin alcanzarla.

El error (Loss) oscila violentamente o aumenta en lugar de bajar.

3. ¿Cuántas épocas tarda en converger?

Rápida (ReLU/Tanh + 0.03): Entre 200 y 300 épocas.

Lenta (Sigmoid + 0.0001): Más de 9,000 épocas (en tu captura todavía no terminaba de converger).

Ejercicio 2

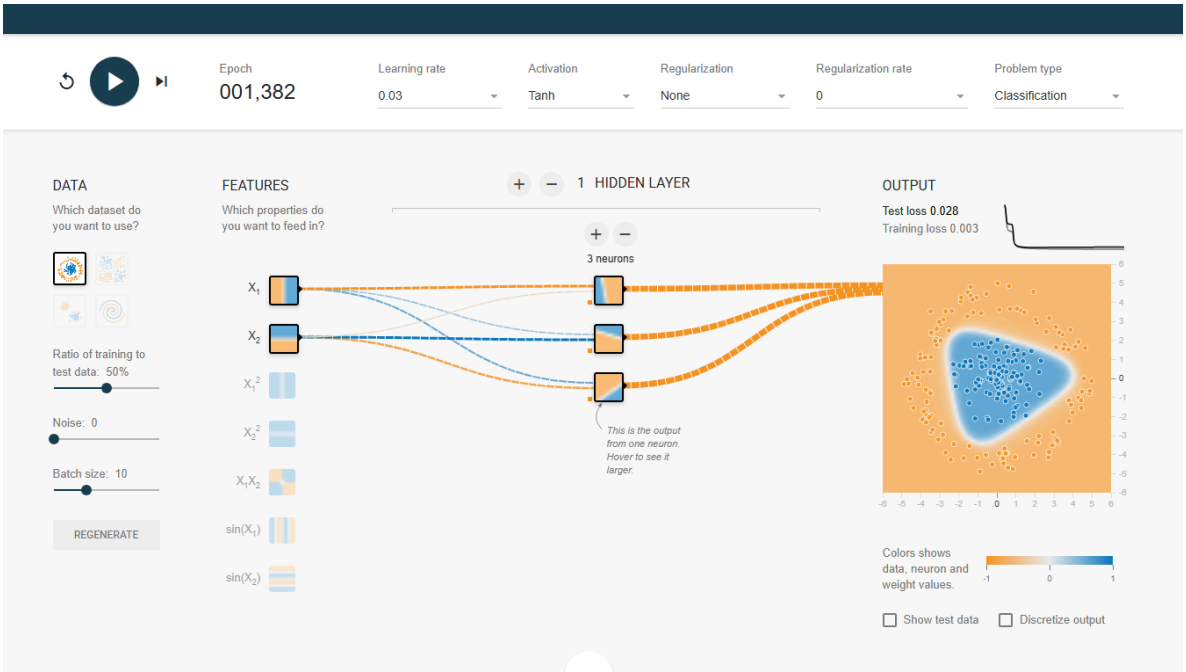

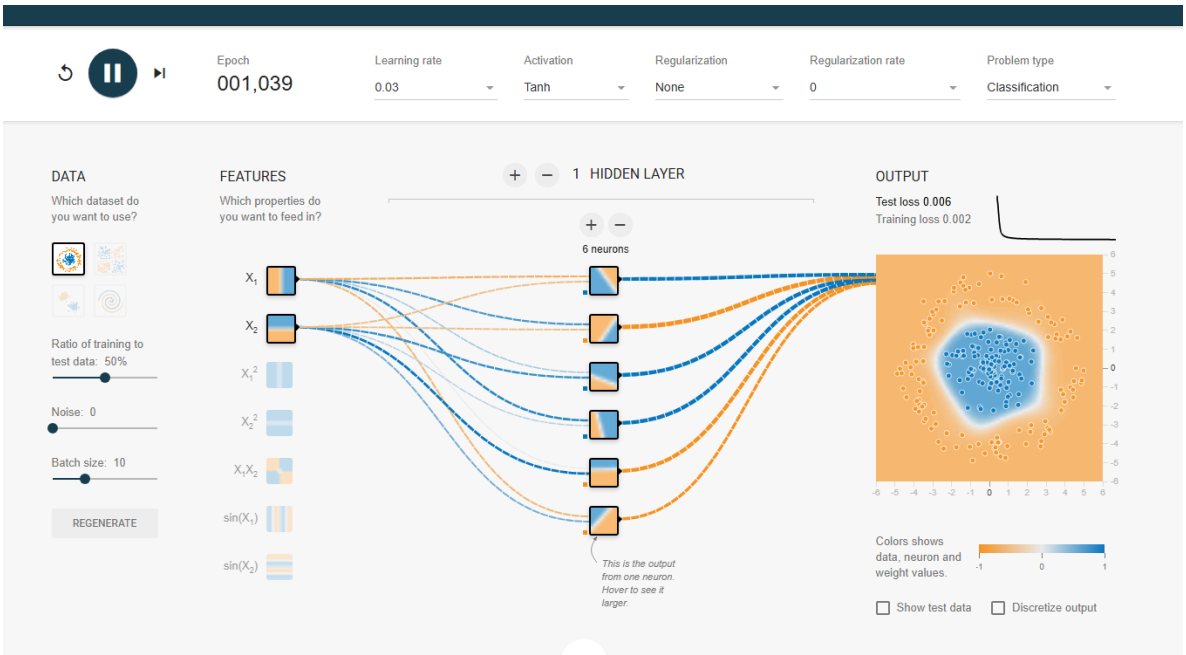

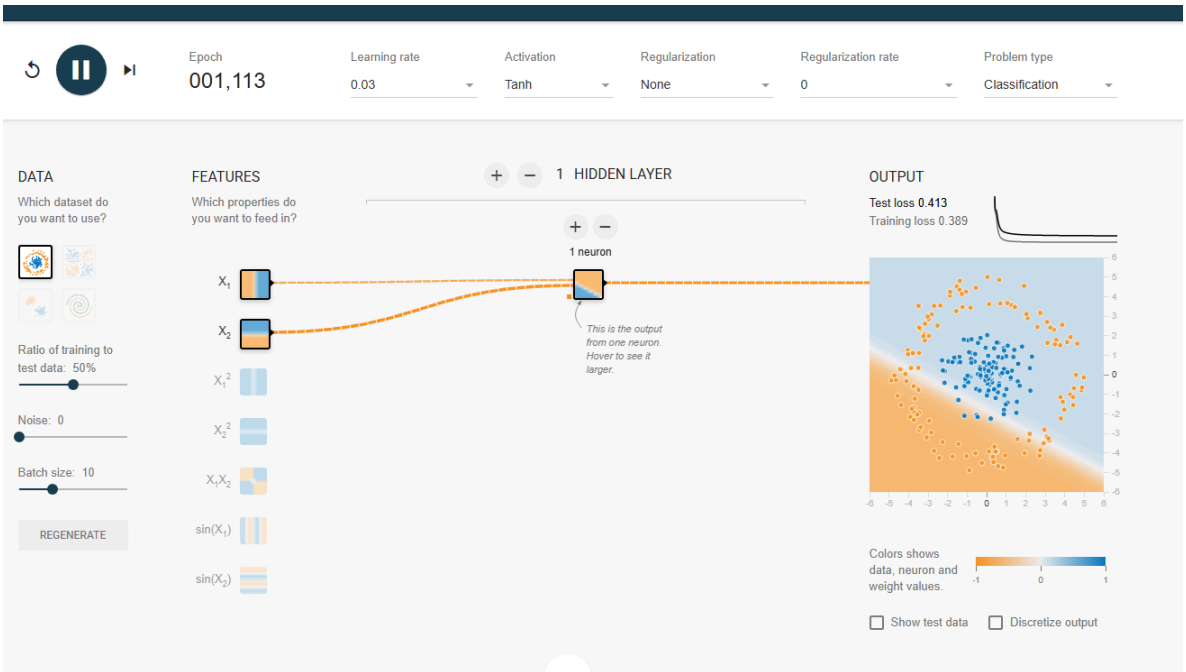

1. ¿Qué ocurre con pocas neuronas?

La red no puede aprender el patrón.

Con 1 sola neurona, solo puede trazar una línea recta (como se ve en la última foto), lo que deja muchísimos puntos mal clasificados (Loss de 0.413).

2. ¿Cómo cambia la frontera de decisión?

Se vuelve más compleja y curva.

Con 3 neuronas, la frontera parece un triángulo.

Con 6 neuronas, se ajusta mucho mejor a la forma circular de los datos, volviéndose más redondeada y precisa.

3. ¿Qué ocurre si agregas una segunda capa?

La red gana capacidad de abstracción.

Permite combinar las formas simples de la primera capa para crear figuras mucho más intrincadas y precisas.

Ayuda a resolver problemas más difíciles (como la espiral) con mayor eficiencia que simplemente añadiendo cientos de neuronas a una sola capa.

Ejercicio 3

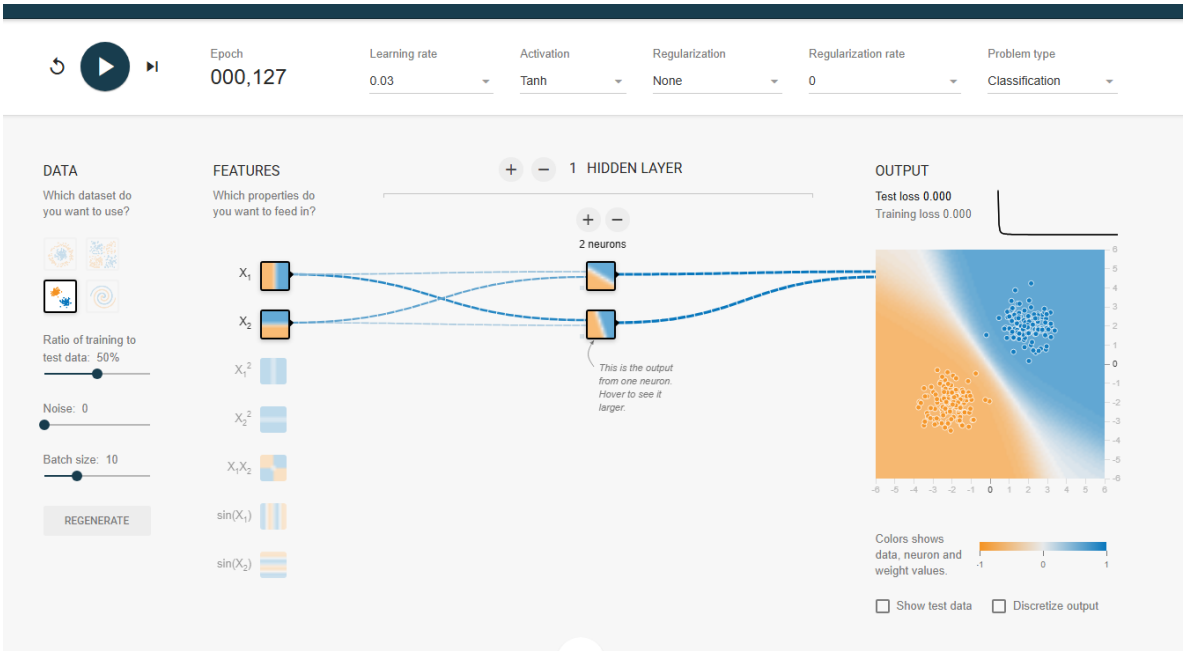

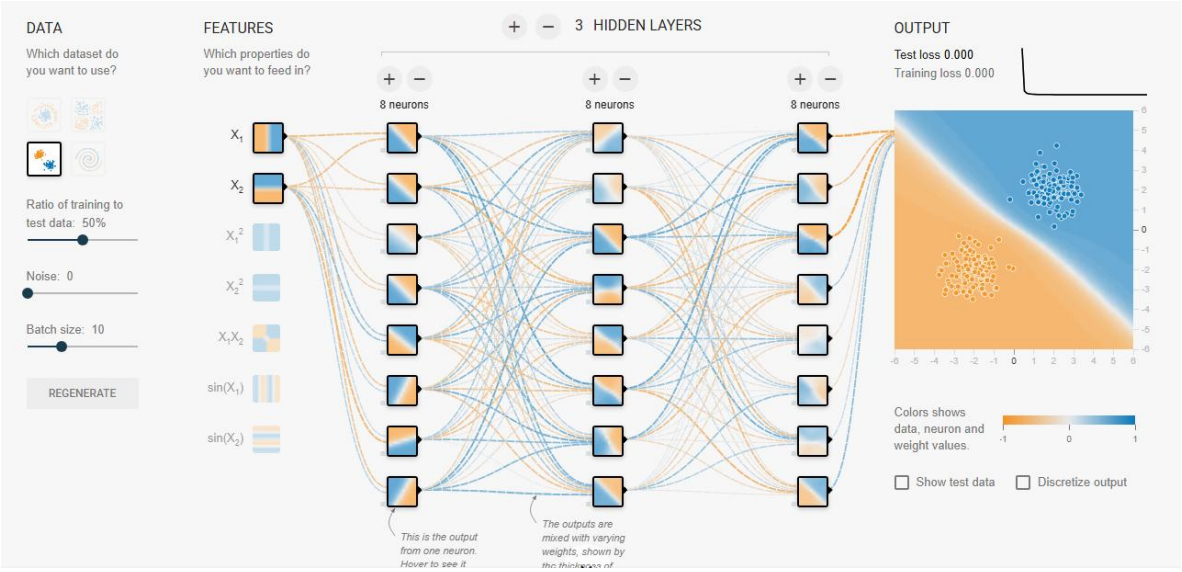

1. ¿La red mejora realmente?

No. Para este problema sencillo (dos grupos separados), la red gigante no aporta nada nuevo. Ambas logran error cero, pero la red compleja desperdicia recursos.

2. ¿Se vuelve más irregular la frontera?

Sí. Al tener tantas neuronas, la línea divisoria pierde su limpieza y empieza a mostrar ángulos u ondulaciones innecesarias, tratando de ajustarse demasiado a cada punto.

3. ¿Qué indica eso sobre el sobreajuste?

Indica que la red está memorizando en lugar de aprender.

Al ser demasiado flexible, corre el riesgo de "perseguir" errores o ruido en los datos, lo que la hará fallar cuando se enfrente a clientes nuevos.

Ejercicio 4

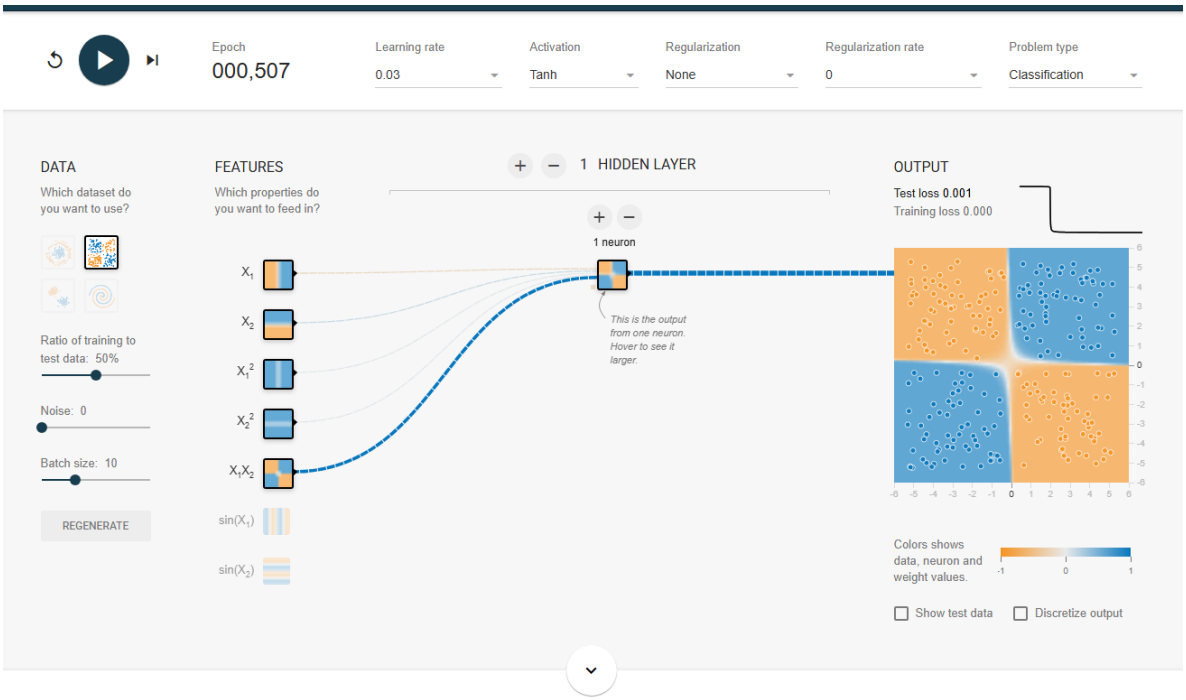

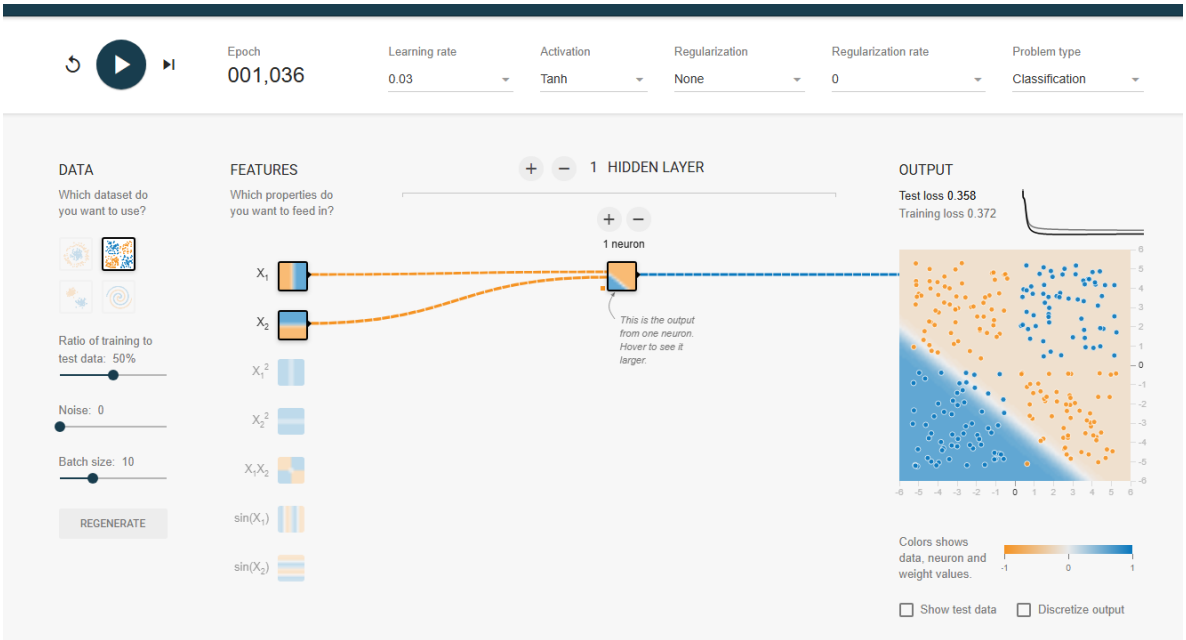

¿Mejora la clasificación?

Sí, drásticamente. Con solo $_1 y X_2 la red falla (Loss 0.358), pero al usar la característica adecuada el error cae a 0.001.

¿Qué feature ayuda más a resolver el problema?

El feature X_1X_2. Al ser un problema de tipo cruzado, esta interacción matemática permite a una sola neurona separar los cuatro cuadrantes de forma eficiente.

Ejercicio 5

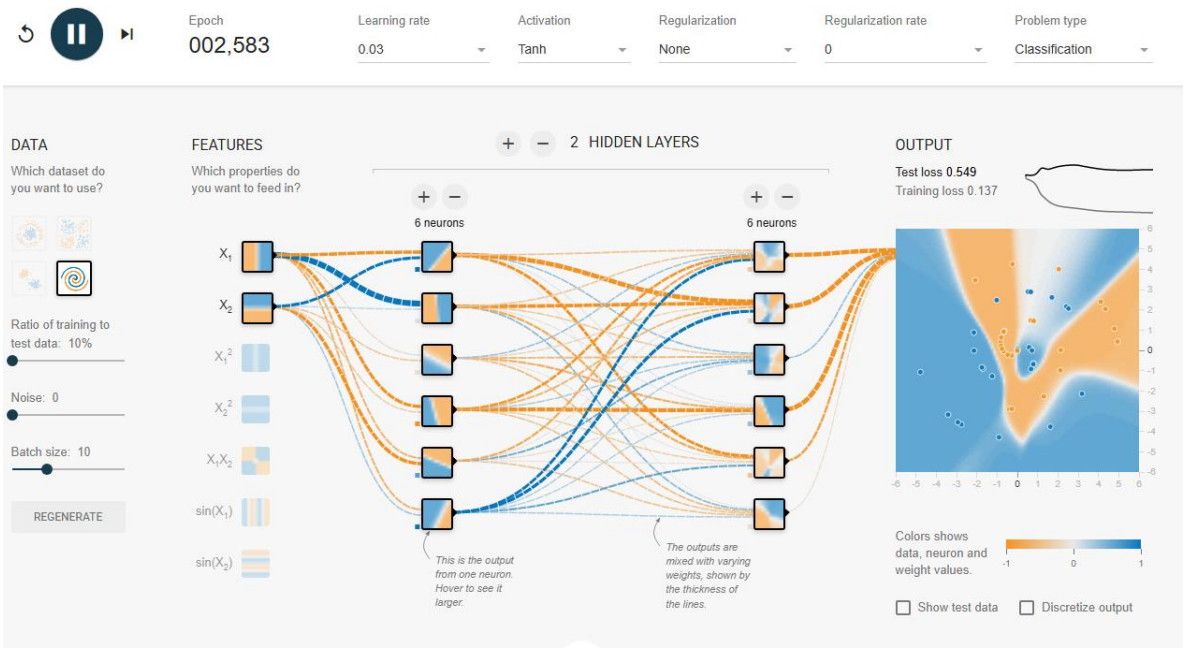

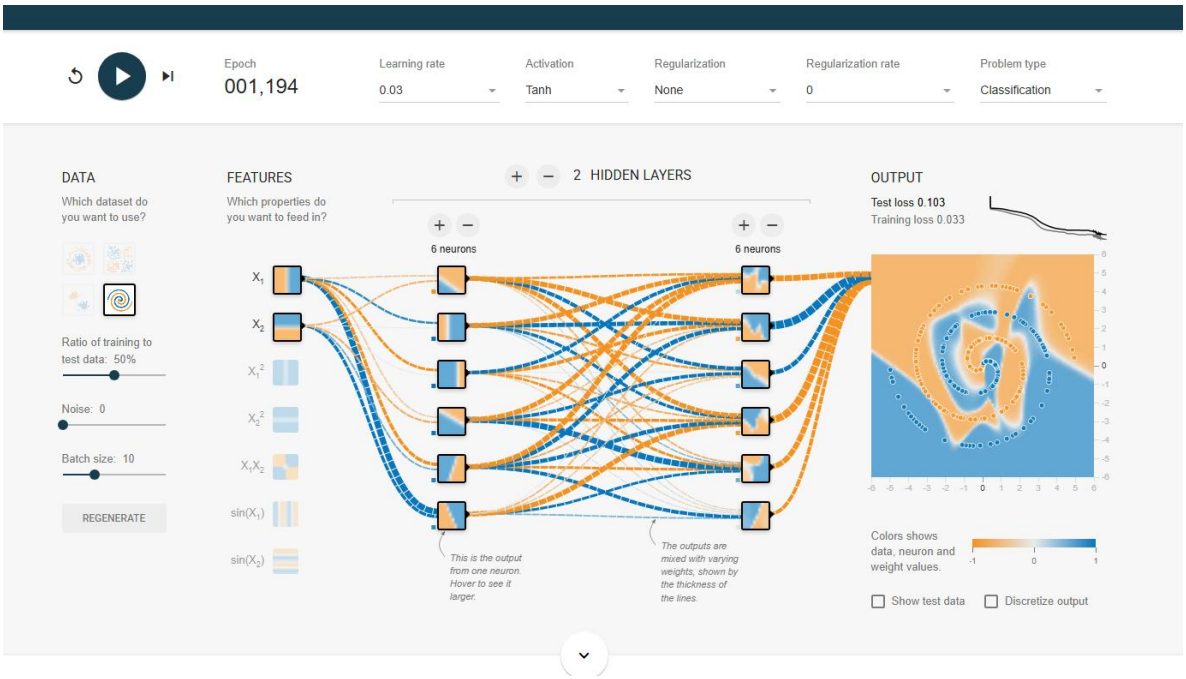

¿La frontera mejora?

Sí. Al subir el Ratio of training data al 70% y usar Regularización L2, la frontera es más suave, estable y no se distorsiona por el ruido de puntos individuales.

¿La red tarda más en entrenar?

Sí. Más datos y capas profundas exigen más cálculos. Un Learning rate muy bajo (0.0001) hace que la convergencia sea lentísima, superando las 8,000 épocas.

Ejercicio 6

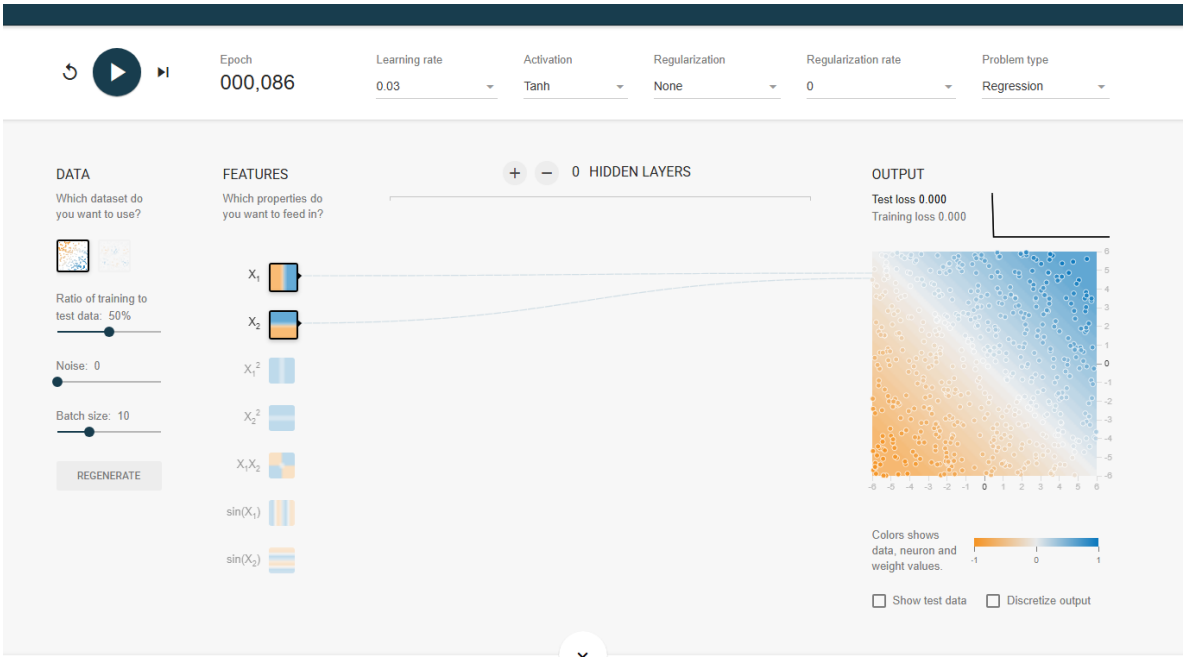

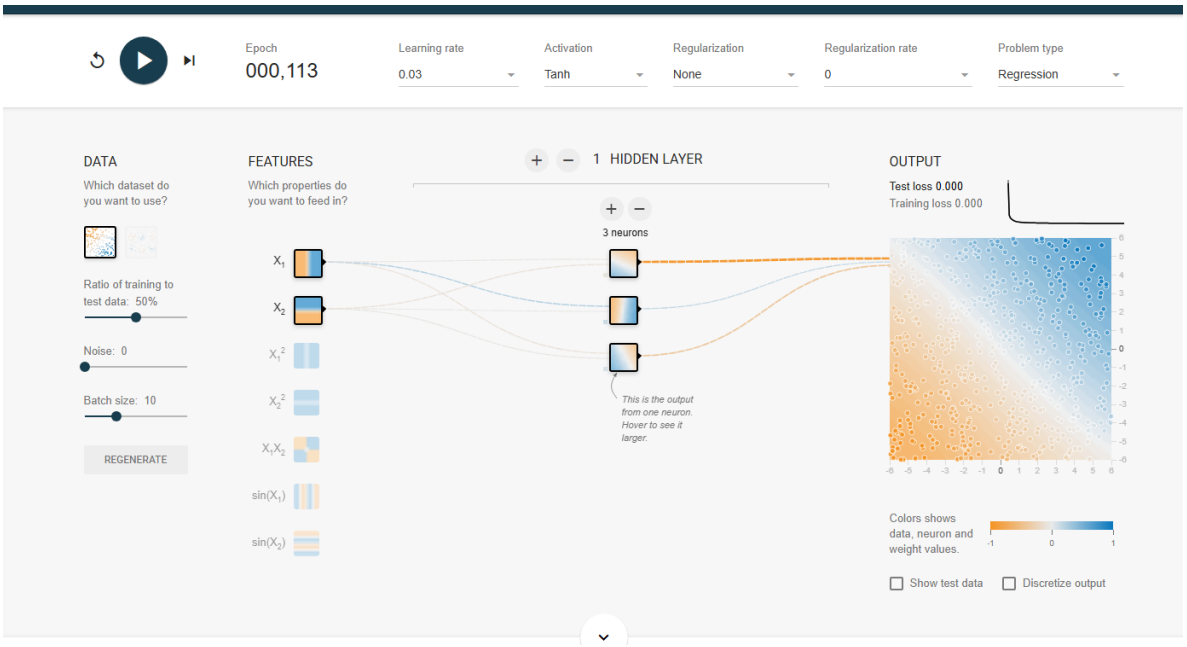
Epoch
000,113
Learning rate
0.03
Activation
Tanh
Regularization
None
Regularization rate
0
Problem type
Regression
DATA
Which dataset do you want to use?
Ratio of training to test data: 50%
Noise: 0
Batch size: 10
REGENERATE
FEATURES
Which properties do you want to feed in?
1 HIDDEN LAYER
3 neurons
This is the output from one neuron. Hover to see it larger.
OUTPUT
Test loss 0.000
Training loss 0.000
Colors shows data, neuron and weight values.
Show test data
Discretize output

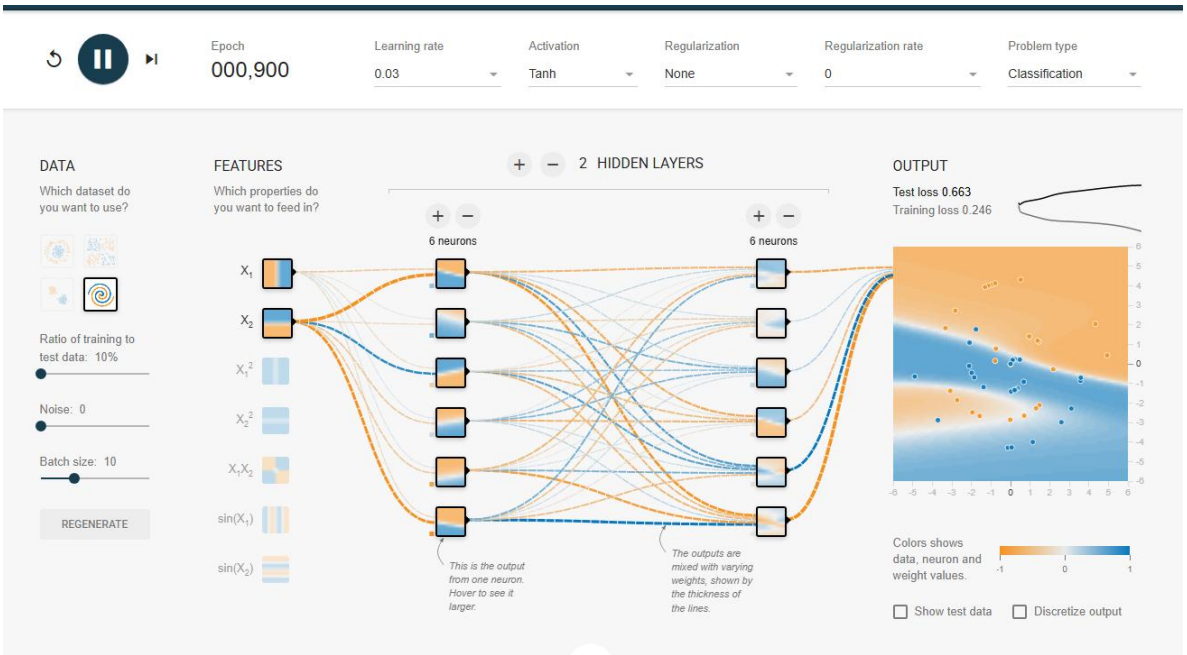
Epoch
000,900
Learning rate
0.03
Activation
Tanh
Regularization
None
Regularization rate
0
Problem type
Classification
DATA
Which dataset do you want to use?
Ratio of training to test data: 10%
Noise: 0
Batch size: 10
REGENERATE
FEATURES
Which properties do you want to feed in?
2 HIDDEN LAYERS
6 neurons
6 neurons
This is the output from one neuron. Hover to see it larger.
The outputs are mixed with varying weights, shown by the thickness of the lines.
OUTPUT
Test loss 0.663
Training loss 0.246
Colors shows data, neuron and weight values.
Show test data
Discretize output

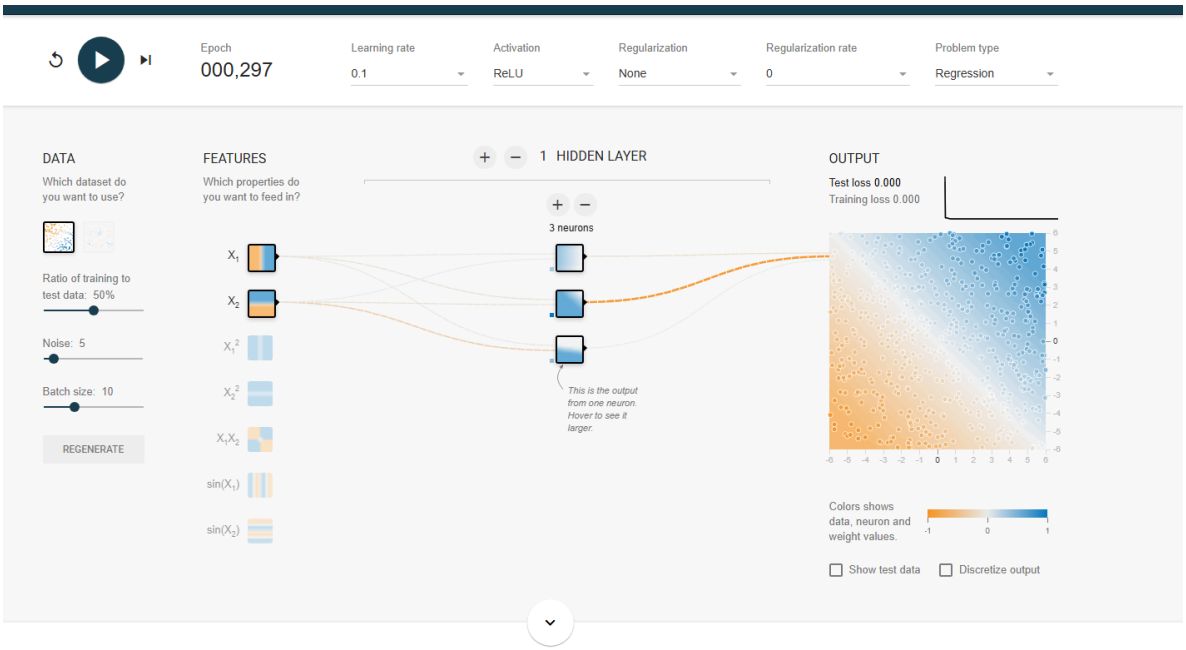

¿Qué cambia en la forma de la función?

La frontera pasa de ser angular y poligonal con ReLU a ser curva y redondeada con Tanh o Sigmoid.

¿Se vuelve más flexible?

Sí. ReLU y Tanh se adaptan rápido a formas complejas, mientras que Sigmoid es mucho más rígida y lenta para moldearse.

Ejercicio 7

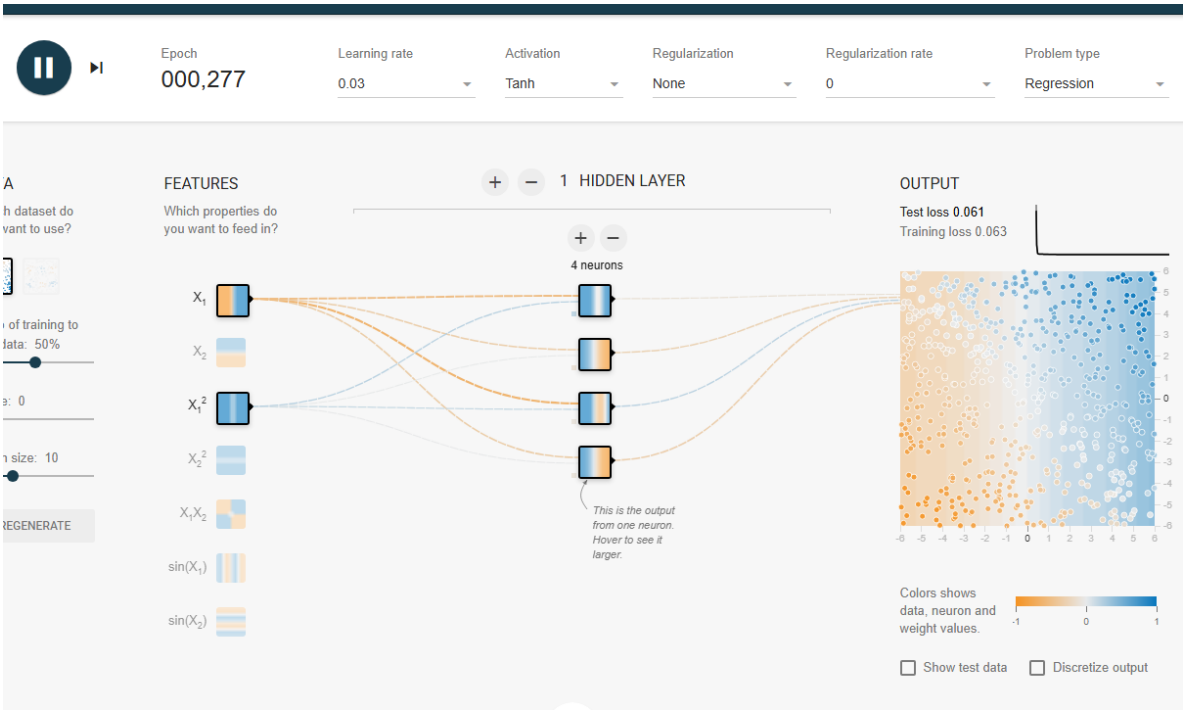

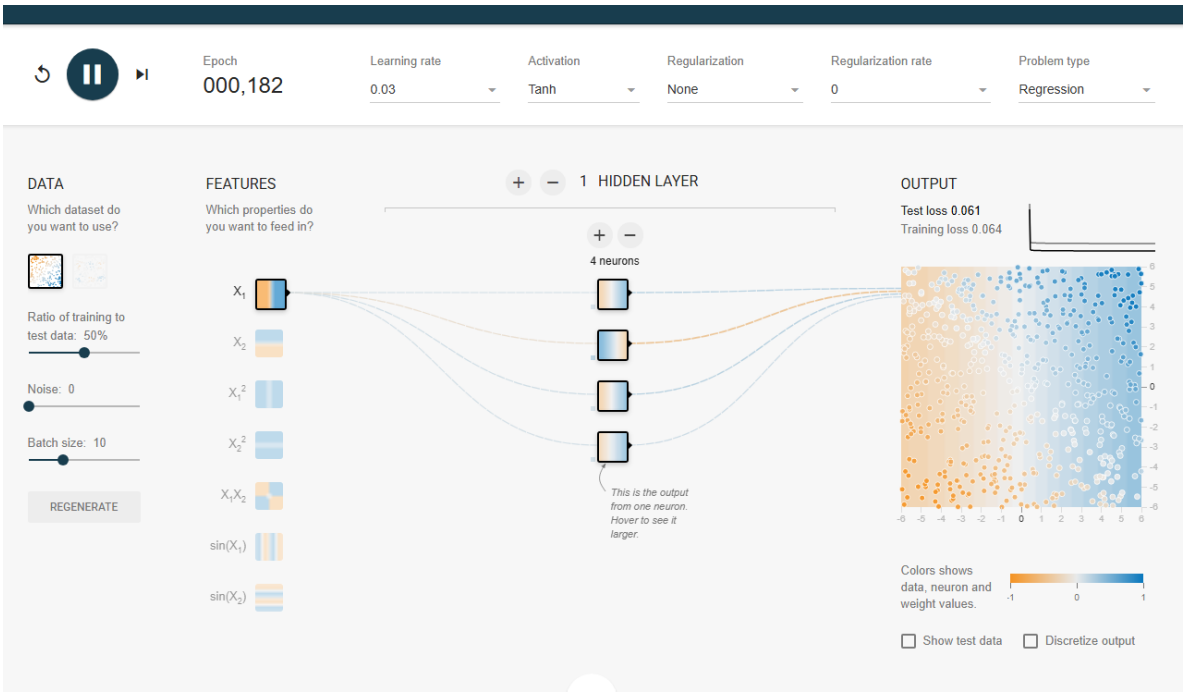

¿La red pierde capacidad de ajuste?

Sí. La frontera de decisión se vuelve mucho más simple y rígida, dejando de "perseguir" los puntos individuales. En tus imágenes, el error de entrenamiento sube ligeramente mientras la frontera se suaviza.

¿Por qué?

Porque la regularización añade un castigo a los pesos de las neuronas. Esto obliga a la red a mantener los pesos pequeños, impidiendo que cree formas demasiado complejas o "caprichosas" para ajustarse al ruido de los datos.

Ejercicio 8

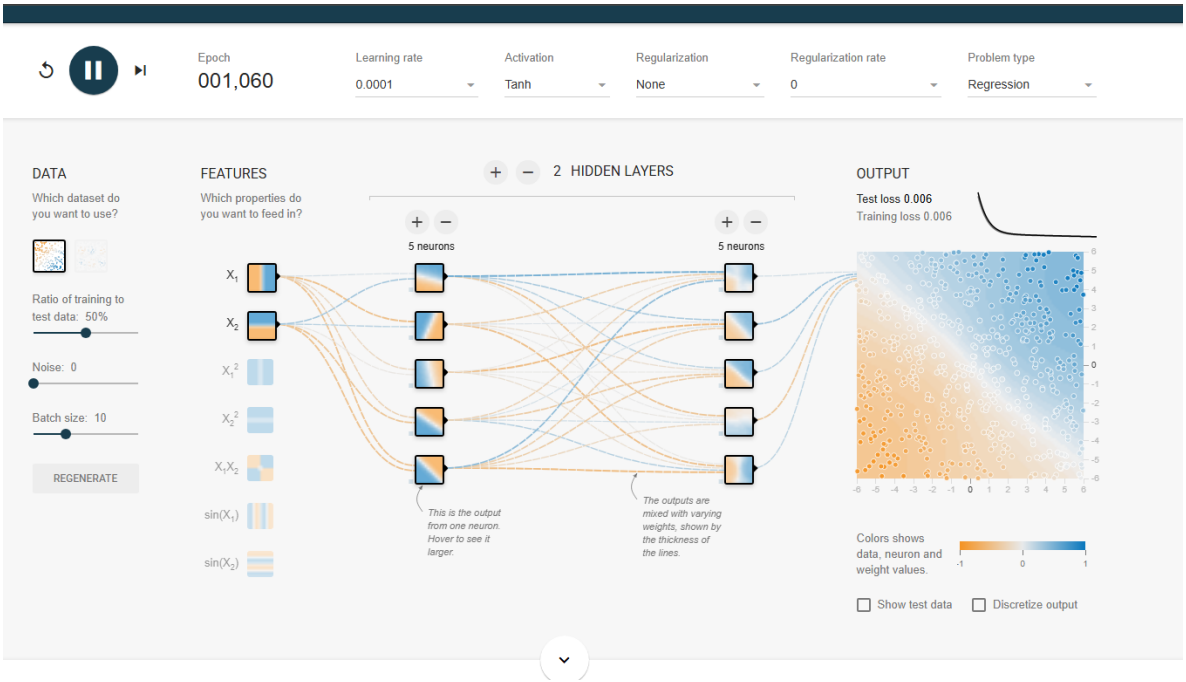
Epoch
001,060
Learning rate
0.0001
Activation
Tanh
Regularization
None
Regularization rate
0
Problem type
Regression
DATA
Which dataset do you want to use?
Ratio of training to test data: 50%
Noise: 0
Batch size: 10
REGENERATE
FEATURES
Which properties do you want to feed in?
2 HIDDEN LAYERS
5 neurons
5 neurons
This is the output from one neuron. Hover to see it larger.
The outputs are mixed with varying weights, shown by the thickness of the lines.
OUTPUT
Test loss 0.006
Training loss 0.006
Colors shows data, neuron and weight values.
Show test data
Discretize output

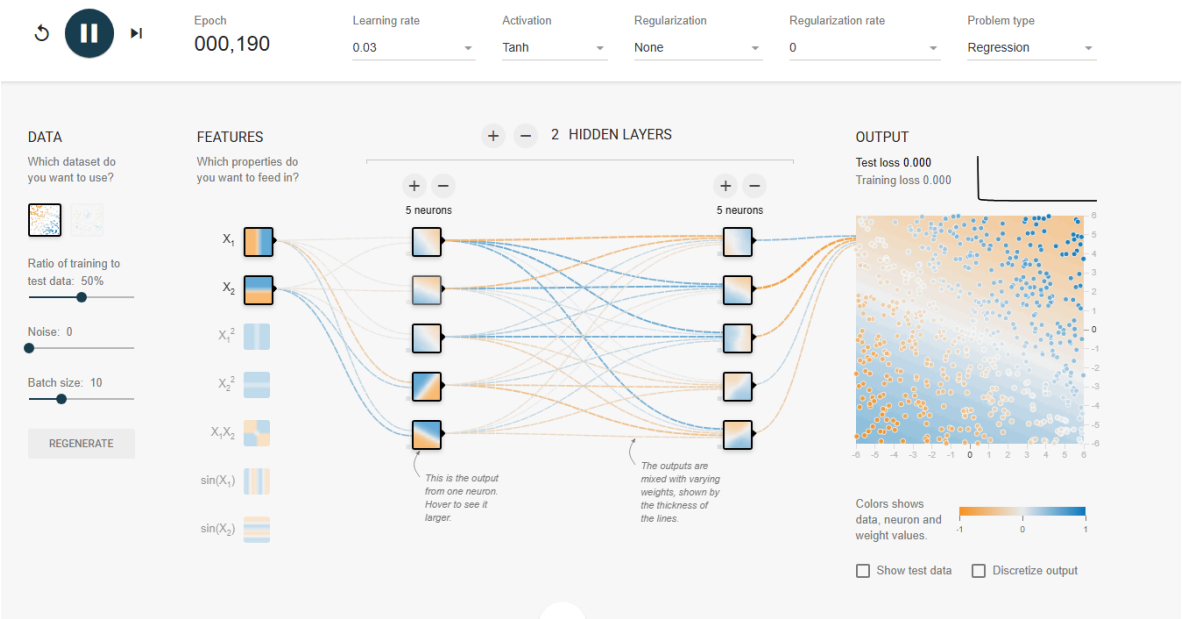

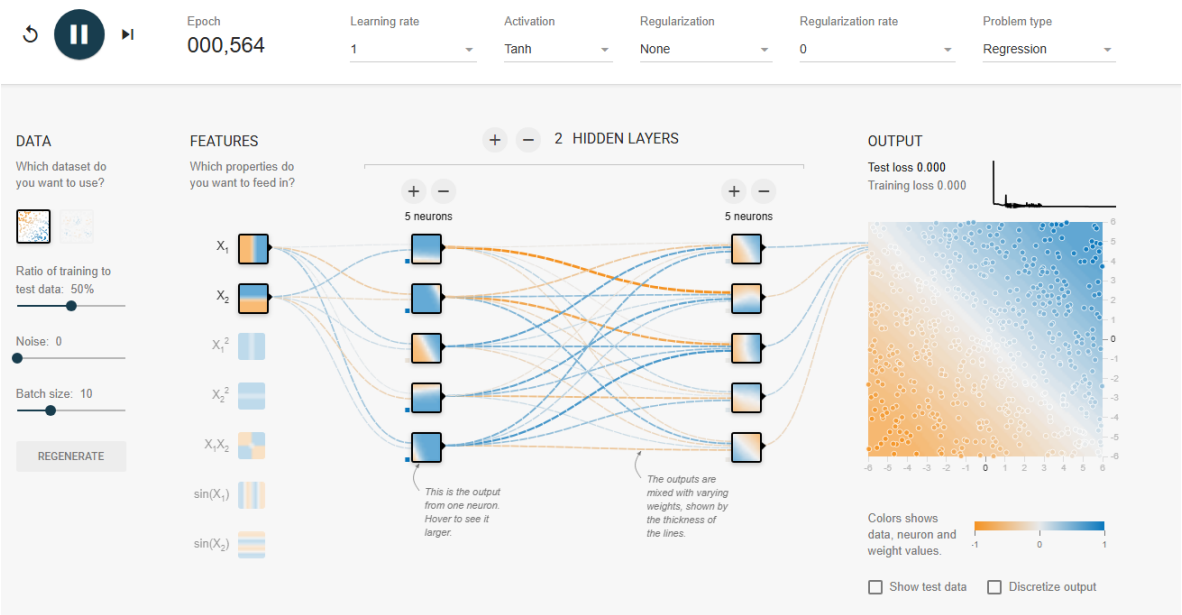

¿Cuál converge más rápido?

La configuración con 0.1, la red logra un error de 0.000 en solo 82 épocas.

¿Cuál diverge?

La configuración con 10, el error se queda estancado en 0.439 y la frontera de decisión se rompe por completo debido a que los pasos son demasiado grandes.

Ejercicio 9

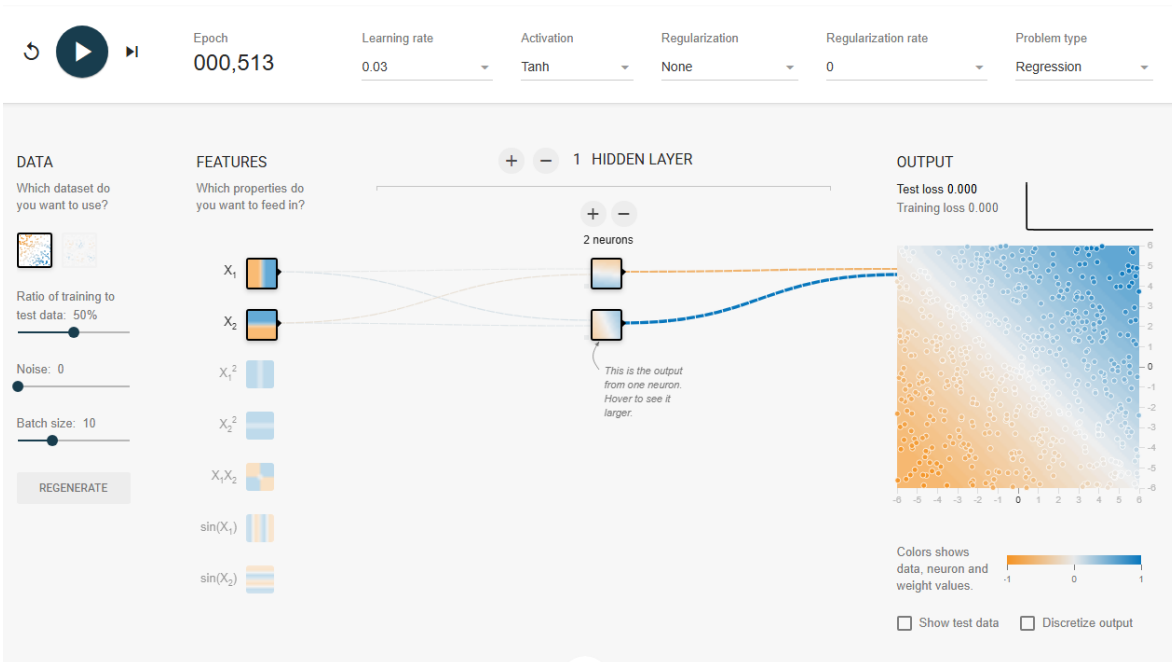
Epoch
000,513
Learning rate
0.03
Activation
Tanh
Regularization
None
Regularization rate
0
Problem type
Regression
DATA
Which dataset do you want to use?
Ratio of training to test data: 50%
Noise: 0
Batch size: 10
REGENERATE
FEATURES
Which properties do you want to feed in?
1 HIDDEN LAYER
2 neurons
This is the output from one neuron. Hover to see it larger.
OUTPUT
Test loss 0.000
Training loss 0.000
Colors shows data, neuron and weight values.
Show test data
Discretize output

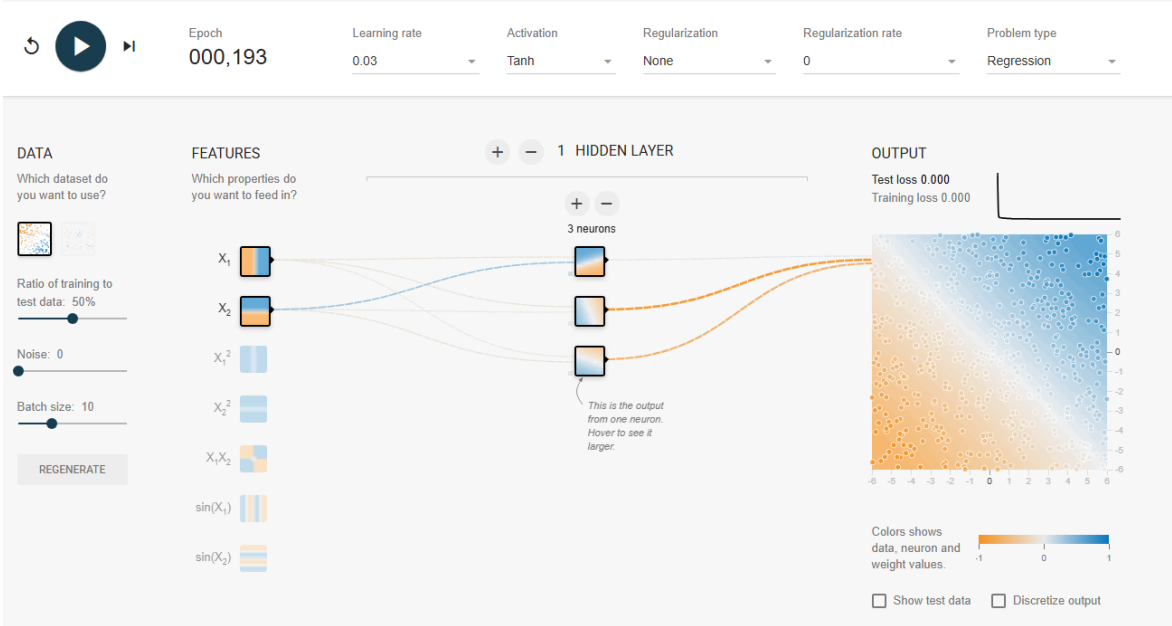
Epoch
000,193
Learning rate
0.03
Activation
Tanh
Regularization
None
Regularization rate
0
Problem type
Regression
DATA
Which dataset do you want to use?
Ratio of training to test data: 50%
Noise: 0
Batch size: 10
REGENERATE
FEATURES
Which properties do you want to feed in?
1 HIDDEN LAYER
3 neurons
This is the output from one neuron. Hover to see it larger.
OUTPUT
Test loss 0.000
Training loss 0.000
Colors shows data, neuron and weight values.
Show test data
Discretize output

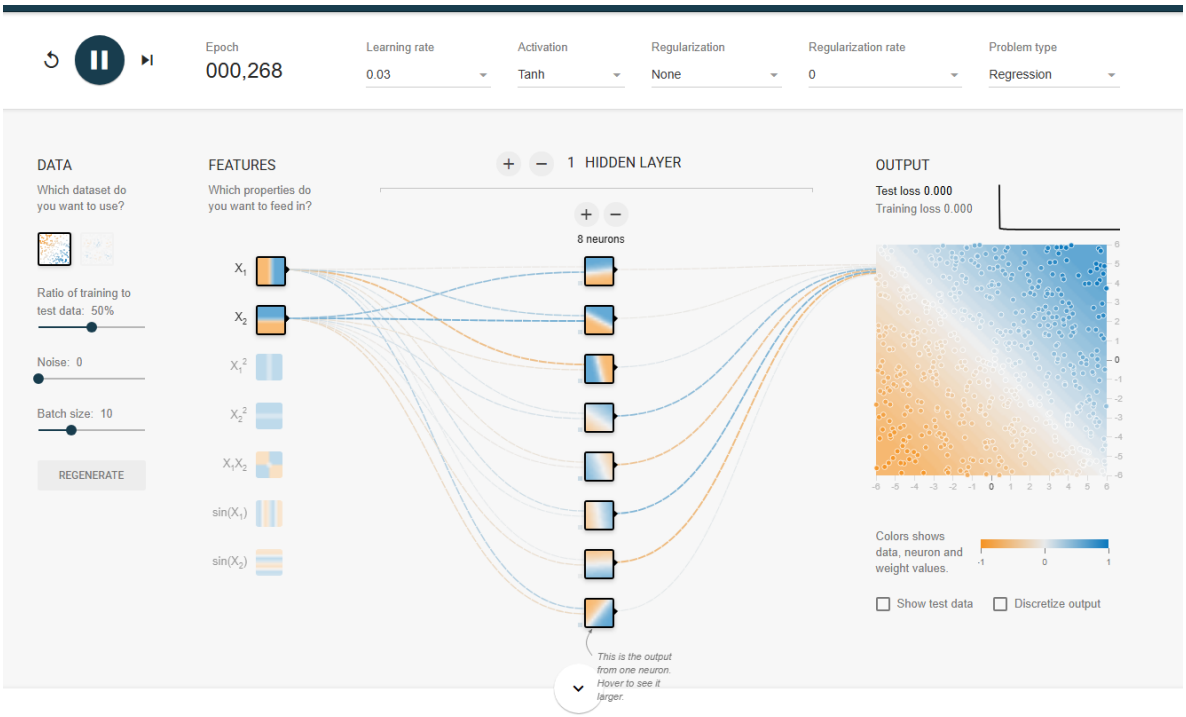

¿La función predicha se vuelve más compleja?

Sí. Con una sola capa la frontera es casi una línea recta o una curva muy simple. Al llegar a 6 capas, la red logra moldear formas mucho más intrincadas y precisas para rodear los datos.

¿Qué implica mayor profundidad?

Implica una jerarquía de características. Las primeras capas aprenden formas básicas (líneas), mientras que las capas profundas combinan esas líneas para entender patrones complejos (curvas, círculos o espirales).

Ejercicio 10

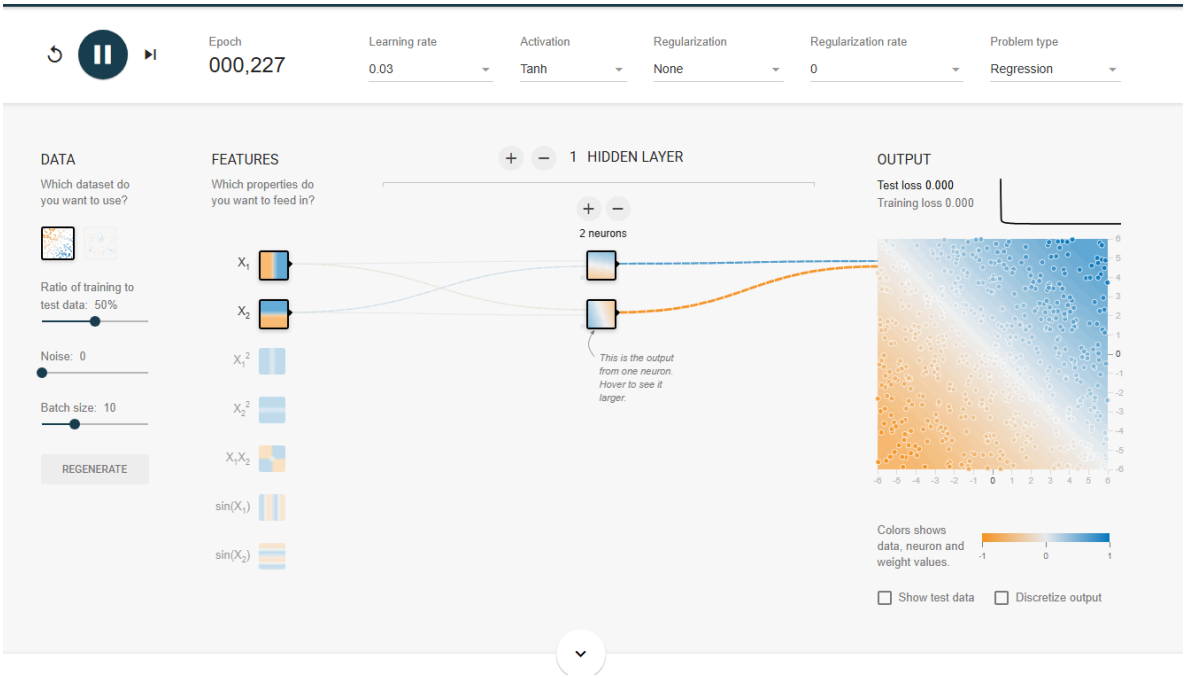

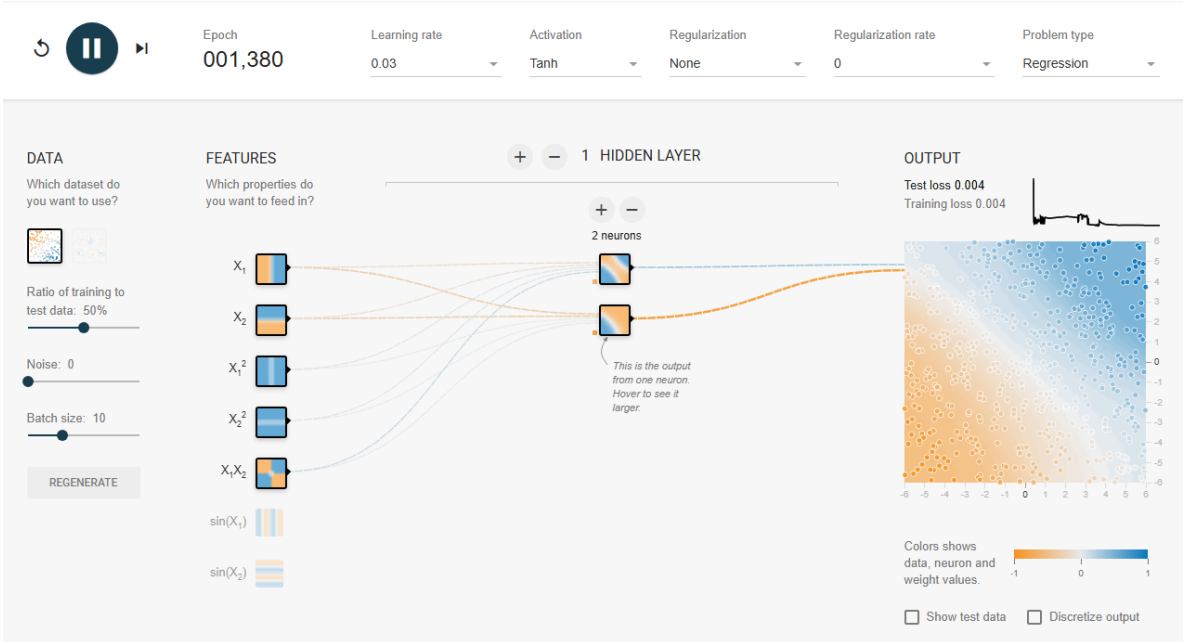

¿Disminuye el error?Sí. Al añadir características como X_1^2, X_2^2 o X_1X_2, el Test loss baja de valores altos (como 0.439) a casi cero (0.001), permitiendo que la red resuelva patrones que antes no podía.¿Qué significa añadir nuevas características?Significa darle a la red pistas matemáticas más ricas sobre los datos. En lugar de que la red intente adivinar formas complejas solo con líneas rectas (X_1, X_2), tú le entregas directamente la noción de curvas, círculos o interacciones, facilitando enormemente el aprendizaje.